

Mô Hình Xử Lý Ngôn Ngữ Tự Nhiên Tiếng Việt Dựa Trên Kiến Trúc Transformer

Tác giả: ThS. Trần Thị Mai & Nhóm Nghiên Cứu NLP | Cụm: Trí Tuệ Nhân Tạo & Học Máy | Mã tài liệu: #1002

TÓM TẮT (ABSTRACT):

Phát triển mô hình ngôn ngữ tiếng Việt tiền huấn luyện đa nhiệm phục vụ phân loại văn bản, tóm tắt tự động và trích xuất thực thể tên riêng (NER).

CÔNG TRÌNH NGHIÊN CỨU: XỬ LÝ NGÔN NGỮ TỰ NHIÊN TIẾNG VIỆT

1. GIỚI THIỆU VÀ ĐẶT VẤN ĐỀ

Xử lý ngôn ngữ tự nhiên (Natural Language Processing - NLP) cho tiếng Việt đối mặt với nhiều đặc thù phức tạp do tính chất đơn lập, hiện tượng từ ghép đa âm tiết không có ranh giới từ hiển thị bằng khoảng trắng, và sự phụ thuộc nặng nề vào ngữ cảnh thanh điệu. Các mô hình dựa trên mạng hồi quy RNN hay LSTM trước đây thường gặp khó khăn khi xử lý các chuỗi văn bản dài do vấn đề suy giảm đạo hàm (vanishing gradient).

2. PHƯƠNG PHÁP VÀ KIẾN TRÚC MÔ HÌNH TRANSFORMER

Để khắc phục hạn chế trên, chúng tôi xây dựng mô hình ngôn ngữ tiền huấn luyện dựa trên kiến trúc Transformer với cơ chế tự chú ý đa đầu (Multi-Head Self-Attention). Mô hình sử dụng bộ mã hóa gồm 12 tầng (Transformer layers), 768 chiều ẩn (hidden dimension), và 12 đầu chú ý độc lập. Quá trình tách từ sử dụng thuật toán Byte-Pair Encoding (BPE) tùy biến riêng cho bảng chữ cái tiếng Việt với kích thước từ vựng (vocabulary size) là 45.000 subwords.

3. DỮ LIỆU HUẤN LUYỆN VÀ CHIẾN LƯỢC HỌC

Kho ngữ liệu tiền huấn luyện được tổng hợp từ hơn 20GB văn bản tiếng Việt số hóa, bao gồm báo điện tử, bài báo khoa học, và tài liệu bách khoa toàn thư. Mô hình được huấn luyện theo hai nhiệm vụ chính: Masked Language Modeling (chiếm 80%) và Next Sentence Prediction (chiếm 20%) trong suốt 500.000 bước huấn luyện trên hạ tầng tính toán phân tán.

4. KẾT QUẢ ĐỐI SÁNH THỰC NGHIỆM

Chúng tôi đánh giá mô hình trên ba tác vụ cốt lõi của thư viện số:

- Phân loại chủ đề văn bản: Đạt điểm F1-Score là 95.8%, cao hơn 6.2% so với mô hình Bi-LSTM.
- Nhận dạng thực thể tên riêng (NER): Đạt độ chính xác 92.4% trên tập nhãn thực thể tổ chức, địa danh và tác giả.
- Tóm tắt văn bản tự động: Chỉ số ROUGE-1 đạt 46.8 và ROUGE-L đạt 41.5, tạo ra các bản tóm tắt trích xuất và diễn giải mạch lạc.

5. KẾT LUẬN VÀ ĐÓNG GÓP

Mô hình Transformer tiếng Việt đề xuất tạo nền tảng vững chắc cho hệ thống quản lý thư viện số tự động, cho phép lập chỉ mục ngữ nghĩa sâu và gợi ý tài liệu học thuật theo ngữ cảnh một cách thông minh.