

Khai Phá Dữ Liệu Lớn và Thuật Toán Phân Cụm Tài Liệu Học Thuật Tự Động

Tác giả: PGS.TS. Lê Hoàng Minh, Viện Công Nghệ Thông Tin | Cụm: Trí Tuệ Nhân Tạo & Học Máy | Mã tài liệu: #1003

TÓM TẮT (ABSTRACT):

Khảo sát và đối sánh các thuật toán phân cụm K-Means, Hierarchical và DBSCAN trên tập văn bản số hóa lớn của thư viện trường đại học.

BÀI BÁO KHOA HỌC: KHAI PHÁ DỮ LIỆU VĂN BẢN VÀ PHÂN CỤM HỌC THUẬT

1. TỔNG QUAN BÀI TOÁN PHÂN NHÓM TÀI LIỆU

Sự bùng nổ của tài liệu học thuật số hóa trong các thư viện hiện đại đòi hỏi các phương pháp tự động hóa khâu phân loại nhằm tiết kiệm nhân lực thủ thư và nâng cao hiệu quả tìm kiếm. Bài toán phân cụm không giám sát (unsupervised clustering) cho phép tự động gom các văn bản có ngữ nghĩa tương đồng thành từng nhóm chuyên đề mà không cần gán nhãn thủ công từ trước.

2. QUY TRÌNH XỬ LÝ VÀ TRÍCH XUẤT ĐẶC TRƯNG TF-IDF

Quy trình thực hiện bao gồm các giai đoạn chuẩn hóa:

- Làm sạch ký tự đặc biệt, chuẩn hóa chữ thường và bảo toàn dấu tiếng Việt.
- Tách từ vựng và loại bỏ các từ dừng chức năng phổ biến (stopwords).
- Xây dựng ma trận TF-IDF (Term Frequency - Inverse Document Frequency) với kích thước từ vựng tối đa 1.500 đặc trưng nổi bật nhất, áp dụng chuẩn hóa vector L2 để đồng nhất độ dài tài liệu.

3. ĐỐI SÁNH THỰC NGHIỆM 3 THUẬT TOÁN CỐT LÕI

Thực nghiệm được triển khai trên 900 tài liệu thuộc 6 lĩnh vực khoa học khác nhau:

- K-Means (với khởi tạo K-Means++ và độ đo Cosine): Đạt Silhouette Score 0.0275, Purity đạt 57.56%, thời gian hội tụ chỉ mất 68.5 ms.
- Hierarchical (Agglomerative với liên kết trung bình): Đạt Purity 50.89%, thời gian thực thi 325.4 ms do chi phí tính toán ma trận khoảng cách $O(N^2)$.
- DBSCAN (Mật độ): Đạt Purity 33.22%, phát sinh nhiều điểm nhiễu ngoại lai do đặc trưng văn bản có số chiều cao và độ thưa lớn.

4. KẾT LUẬN KHOA HỌC

Thuật toán K-Means kết hợp khoảng cách Cosine là lựa chọn tối ưu nhất cho hệ thống thư viện số thực tế, vừa đảm bảo chất lượng phân cụm vừa có khả năng phân loại tức thời (< 2 ms) tài liệu mới thêm vào.